



《大规模语言模型：从理论到实践》

第3章 大语言模型预训练数据

张奇 桂韬 郑锐 黄萱菁

复旦大学



训练大语言模型需要**数万亿**的各类型数据。如何构造海量“高质量”数据对于大语言模型的训练具有至关重要的作用。

截至2023 年9 月，还没有非常好的大语言模型的理论分析和解释，也缺乏对语言模型训练数据的严格说明和定义。但是，大多数研究人员认为**预训练数据是影响大语言模型效果及样本泛化能力**的关键因素之一。

当前的研究表明，预训练数据需要涵盖**各种类型的文本**，也需要覆盖**尽可能多的领域、语言、文化和视角**，从而提高大语言模型的泛化能力和适应性。

目前，大语言模型所采用的预训练数据通常包括网络数据、图书、论文、百科和社交媒体等。

目录

Contents

3.1

数据来源

3.2

数据处理

3.3

数据影响分析

3.4

开源数据集

3.5

实践思考

目录

Contents

3.1

数据来源

3.2

数据处理

3.3

数据影响分析

3.4

开源数据集

3.5

实践思考




文献[5] 介绍了OpenAI 训练GPT-3 所使用的主要数据来源，包含经过过滤的Common-Crawl 数据集 [19]、WebText2、Books1、Books2 以及英文Wikipedia 等数据集。

- CommonCrawl的原始数据有45TB，进行过滤后仅保留了570GB 的数据。通过词元方式对上述语料进行切分，大约包含 5000 亿词元。
- 为了保证模型使用更多高质量数据进行训练，在GPT-3 训练时，根据语料来源的不同，设置不同的采样权重。在完成 3000 亿词元训练时，英文Wikipedia 的语料平均训练轮数为3.4 次，而CommonCrawl 和Books 2 仅有0.44 次和0.43 次。

Meta 公司的研究人员在训练OPT[31] 模型时采用了混合RoBERTa[71]、Pile[72] 和PushShift.io Reddit[73] 数据的方法。由于这些数据集中包含的绝大部分数据都是英文数据，因此OPT 也从CommonCrawl 数据集中抽取了部分非英文数据加入训练语料。



大语言模型预训练所需的数据来源大体上分为通用数据和专业数据两大类。**通用数据 (General Data)** 包括网页、图书、新闻、对话文本等内容[14, 31, 46]。通用数据具有规模大、多样性和易获取等特点，因此支持大语言模型的语言建模和泛化能力。**专业数据 (Specialized Data)** 包括多语言数据、科学数据、代码及领域特有资料等。通过在预训练阶段引入专业数据可以有效提升大语言模型的任务解决能力。





通用数据在大语言模型训练数据中占比通常非常高，主要包括来自网页、书籍、对话文本等不同类型的的数据，为大语言模型提供了大规模且多样的训练数据。

网页 (Webpages) 是通用数据中数量最多的一类。随着互联网的大规模普及，人们通过网站、论坛、博客、App 等各种类型网站和应用，创造了海量的数据。根据2016 年Google 公开的数据，其搜索引擎索引处理了超过130 万亿网页。

- 爬取和处理海量网页内容并不是一件容易的事情，因此一些研究人员构建了包括 ClueWeb09[74]、ClueWeb12[75]、SogouT-16[76]、CommonCrawl 等在内的**开源网页数据集**。
- 虽然这些爬取的网络数据包含大量高质量的文本（如维基百科），但也包含非常多低质量的文本（如垃圾邮件等）。因此，**过滤并处理网页以提高数据质量**对大语言模型训练来说非常重要。



对话数据 (Conversation Text) 是指有两个或更多参与者交流的文本内容。对话数据包含书面形式的对话、聊天记录、论坛帖子、社交媒体评论等。当前的一些研究表明，**对话数据可以有效增强语言模型的对话能力**[31]，并潜在地提高其在多种问答任务上的表现[14]。

- 对话数据可以通过收集、清洗、归并等过程从社交媒体、论坛、邮件组等构建。相较于网页数据，对话数据收集和处理更加困难，数据数量也相对少非常多。
- 常见的对话数据集包括PushShift.io Reddit[73, 77]、Ubuntu Dialogue Corpus[78]、Douban Conversation Corpus、Chromium Conversations Corpus 等。
- 文献[79] 也提出了使用大语言模型**自动生成对话数据**的UltraChat 方法。



书籍 (Book) 是人类知识的主要积累方式之一，从古代经典著作到现代学术著述，承载了丰富多样的人类思想。书籍通常包含广泛的词汇，包括专业术语、文学表达及各种主题词汇。利用书籍数据进行训练，大语言模型可以接触多样化的词汇，从而提高其对不同领域和主题的理解能力。

相较于其他语料库，书籍也是最重要的，甚至是唯一的**长文本书面语的数据来源**。

- 书籍提供了完整的句子和段落，使得大语言模型可以学习到上下文之间的联系。这对于模型理解句子中的复杂结构、逻辑关系和语义连贯性非常重要。
- 书籍涵盖了各种文体和风格，包括小说、科学著作、历史记录，等等。通过使用书籍数据训练语言模型，可以使模型学习到不同的写作风格和表达方式，提高大语言模型在各种文本类型上的能力。
- 受限于版权因素，**开源书籍数据集很少**，现有的开源大语言模型研究通常采用Pile 数据集 [72] 中提供的Books3 和Bookcorpus2 数据集。



专业数据在通用大语言模型中所占比例通常较低，但是其对改进大语言模型**在下游任务上的特定能力**有着非常重要的作用。专业数据有非常多的种类，文献[18]总结了当前大语言模型使用的三类专业数据，包括**多语言数据**、**科学文本数据**和**代码**。

多语言数据 (Multilingual Text) 对于增强大语言模型的语言理解和生成多语言能力具有至关重要的作用。当前的大语言模型训练除了需要目标语言中的文本，通常还要整合多语言语料库。

- BLOOM[33] 的预训练语料中包含46种语言，PaLM[14] 的训练语料中甚至包含高达122种语言的数据。此前的研究发现，通过多语言混合训练，预训练模型可以在一定程度上**自动构建多语言之间的语义关联**[80]。
- 多语言数据混合训练，**可以有效提升翻译、多语言摘要和多语言问答**等任务能力。此外，由于不同语言中不同类型的知识获取难度不同，多语言数据还可以有效地增加数据的多样性和知识的丰富性。



科学文本 (Scientific Text) 数据包括教材、论文、百科及其他相关资源。这些数据对于提升大语言模型在理解科学知识方面的能力具有重要作用[34]。

- 科学文本数据的**来源**主要包括arXiv 论文[81]、PubMed 论文[82]、教材、课件和教学网页等。
- 由于科学领域涉及众多专业领域且数据形式复杂，通常还需要对公式、化学式、蛋白质序列等**采用特定的符号标记并进行预处理**。这样可以将不同格式的数据转换为统一的形式，使大语言模型更好地处理和分析科学文本数据。
 - **公式**可以用LaTeX 语法表示
 - **化学结构**可以用SMILES (Simplified Molecular Input Line EntrySystem) 表示
 - **蛋白质序列**可以用单字母代码或三字母代码表示



代码（Code） 数据是进行程序生成任务所必需的训练数据。近期的研究和 ChatGPT 的结果表明，通过在大量代码上进行预训练，大语言模型可以有效提升代码生成的效果[83-84]。

- 代码数据不仅包含程序代码本身，还包含大量的注释信息。与自然语言文本相比，代码数据具有显著的不同。**代码是一种格式化语言**，它对应着长程依赖和准确的执行逻辑[85]。代码的语法结构、关键字和特定的编程范式都对其含义和功能起着重要的作用。
- **代码数据的主要来源**是编程问答社区（如Stack Exchange[86-87]）和公共软件仓库（如GitHub[29, 83, 88]）。
 - **编程问答社区**中的数据包含了开发者提出的问题、其他开发者的回答及相关代码示例。这些数据提供了丰富的语境和真实世界中的代码使用场景。
 - **公共软件仓库**中的数据则包含了大量的开源代码，涵盖多种编程语言和不同领域。这些代码库中的很多代码经过了严格的代码评审和实际的使用测试，因此具有一定的质量和可靠性。

目录

Contents

3.1

数据来源

3.2

数据处理

3.3

数据影响分析

3.4

开源数据集

3.5

实践思考



大语言模型的相关研究表明，**数据质量对于模型的影响非常大**。因此，在收集了各种类型的数据之后，需要对数据进行处理，去除低质量数据、重复数据、有害信息、个人隐私等内容[14, 89]。典型的数据处理流程如图3.2 所示，主要包括质量过滤、冗余去除、隐私消除、词元切分这几个步骤。

质量过滤

- 语言过滤
- 指标过滤
- 统计特征过滤
- 关键词过滤

Alice is writing a paper about LLMs. ~~#\$A&~~ Alice is writing a paper about LLMs.

冗余去除

- 句子级别
- 文档级别
- 数据集级别

Alice is writing a paper about LLMs. ~~Alice is writing a paper about LLMs.~~

隐私消除

- 隐私数据发现
- 隐私数据消除

The social security number of Alice is ~~123-45-678.~~

词元切分

- 子词词元化
- 字节对编码
- WordPiece

newest → n/e/w/es/t
low → lo/w
wid → w/id



互联网上的数据质量参差不齐，无论是OpenAI 联合创始人Andrej Karpathy 在微软Build 2023 的报告，还是当前的一些研究都表明，**训练数据的质量对于大语言模型效果具有非常重要的影响**。因此，从收集到的数据中删除低质量数据成为大语言模型训练中的重要步骤。

大语言模型训练中所使用的低质量数据过滤方法可以大致分为两类：**基于分类器的方法**和**基于启发式的方法**。



基于分类器的方法的目标是训练文本质量判断模型，并利用该模型识别并过滤低质量数据。GPT-3[46]、PaLM[14] 和GLaM[90] 模型在训练数据构造时都使用了基于分类器的方法。

文献[90]采用了**基于特征哈希的线性分类器**（Feature Hash Based Linear Classifier），可以非常高效地完成文本质量判断。

- 该分类器使用一组精选文本（维基百科、书籍和一些选定的网站）进行训练，目标是给与训练数据类似的网页较高分数。利用这个分类器可以评估网页的内容质量。
- 在实际应用中，还可以通过使用Pareto 分布对网页进行采样，根据其得分选择合适的阈值，从而选定合适的数据集。

然而，一些研究发现，基于分类器的方法可能会删除包含方言或者口语的高质量文本，从而损失一定的多样性[89-90]。



基于启发式的方法则通过一组精心设计的规则来消除低质量文本，BLOOM[33] 和 Gopher[89]采用了基于启发式的方法。这些启发式规则主要包括：

- **语言过滤**：如果一个大语言模型仅关注一种或者几种语言，则可以大幅过滤数据中其他语言的文本。
- **指标过滤**：利用评测指标也可以过滤低质量文本。例如，可以使用语言模型对给定文本的困惑度（Perplexity）进行计算，利用该值可以过滤非自然的句子。
- **统计特征过滤**：针对文本内容可以计算包括标点符号分布、符号字比（Symbol-to-Word Ratio）、句子长度在内的统计特征，利用这些特征过滤低质量数据。
- **关键词过滤**：根据特定的关键词集，可以识别并删除文本中的噪声或无用元素。例如，HTML标签、超链接及冒犯性词语等。



在大语言模型出现之前，在自然语言处理领域已经开展了很多文章质量判断（Text Quality Evaluation）相关研究，主要应用于搜索引擎、社交媒体、推荐系统、广告排序及作文评分等任务中。

- 在搜索和推荐系统中，结果的内容质量是影响用户体验的重要因素之一，因此，此前很多工作都是针对用户生成内容（User-Generated Content, UGC）的质量进行判断的。
- 自动作文评分也是文章质量判断领域的一个重要子任务，自1998 年文献[91] 提出使用贝叶斯分类器进行作文评分预测以来，基于SVM[92]、CNN-RNN[93]、BERT[94-95] 等方法的作文评分算法也被相继提出，并取得了较大的进展。

这些方法都可以应用于大语言模型预训练数据过滤。由于预训练数据量非常大，并且对质量判断的准确率要求并不非常高，因此一些基于深度学习和预训练的方法还没有应用于低质过滤中。



文本冗余发现 (Text Duplicate Detection) 也称为文本重复检测，是自然语言处理和信息检索中的基础任务之一，其目标是发现不同粒度上的文本重复，包括句子、段落、文档等不同级别。冗余去除就是在不同的粒度上去除重复内容，包括句子、文档和数据集等粒度。

文献[96] 指出，大语言模型训练语料库中的重复数据，会降低大语言模型的多样性，并可能导致训练过程不稳定，从而影响模型性能。因此，需要对预训练语料库中的重复数据进行处理，去除其中的冗余部分。

在句子级别上，文献[97] 指出，包含重复单词或短语的句子很可能造成语言建模中引入重复的模式。这对语言模型来说会产生非常严重的影响，使得模型在预测时容易陷入**重复循环（Repetition Loops）**。

例如：使用GPT-2 模型，对于给定的上下文：“In a shocking finding, scientist discovered a herd of unicorns living in a remote, previously unexplored valley, in the Andes Mountains. Even more surprising to the researchers was the fact that the unicorns spoke perfect English.”。

如果使用束搜索（Beam Search），当设置 $b = 32$ 时，模型就会产生如下输出，进入重复循环模式。

[illegible]



在RefinedWeb[64] 的构造过程中使用了文献[98] 提出的过滤方法，进行了句子级别的过滤。

- 该方法提取并过滤文档间**超过一定长度的相同字符串**。给定两个文档 x_i 和 x_j ，其中存在长度为 k 的公共子串。当 $k \geq 50$ 时，就将其中一个子串过滤。
- 公共子串匹配的关键是如何高效完成字符串匹配，文献[64] 将整个文档 D 转换为一个超长的字符串序列 S ，之后构造序列 S 的**后缀数组 (Suffix Array)** A 。该数组包含在该序列中的所有后缀按字典顺序排列的列表。具体而言，后缀数组 A 是一个整数数组，其中每个元素表示 S 中的一个后缀的起始位置。 A 中的元素按照后缀的字典顺序排列。
- 针对Wiki-40B 训练语料（约包含4GB 文本内容），使用拥有96 核CPU 以及768GB 内存的服务器，可以在140 秒内完成计算。对于包含350GB 文本的C4 数据集，仅需要12 小时就可以完成后缀数组构造。




在文档级别上，大部分大语言模型依靠文档之间的表面特征相似度（例如n-gram重叠比例）进行检测并删除重复文档[33, 37, 64, 98]。

- LLaMA[37] 采用CCNet[99] 的处理模式，先将文档拆分为段落，并把所有字符转换为小写字符、将数字替换为占位符，以及删除所有Unicode标点符号和重音符号来对每个段落进行规范化处理。然后，使用SHA-1方法为每个段落计算一个哈希码（Hash Code），并使用前64 位数字作为键。最后，利用每个段落的键进行重复判断。
- RefinedWeb[64] 先去除页面中菜单、标题、页脚、广告等内容，仅抽取页面中的主要内容。在此基础上，在文档级别进行过滤，采用与文献[89] 类似的方法，使用n-gram 重叠程度来衡量句子、段落及文档的相似度。如果重复程度超过预先设定的阈值，则会过滤重复段落或文档。



由于绝大多数预训练数据源于互联网，因此不可避免地会包含涉及敏感或个人信息 (Personally Identifiable Information, PII) 的用户生成内容，这可能会增加隐私泄露的风险[101]。



如左图所示，输入前缀词 “East Stroudsburg Stroudsburg” ，语言模型在此基础上补全了姓名、电子邮件地址、电话号码、传真号码及实际地址。这些信息都是模型从预训练语料中学习得到的。

因此，非常有必要从预训练语料库中删除包含个人身份信息的内容。



删除隐私数据最直接的方法是采用基于规则的算法，BigScience ROOTS Corpus[102] 在构建过程中就采用了[基于命名实体识别的方法](#)，利用命名实体识别算法检测姓名、地址、电话号码等个人信息内容并进行删除或者替换。

该方法使用了基于Transformer 的模型，并结合机器翻译技术，可以处理超过100种语言的文本，消除其中的隐私信息。该方法被集成在muliwai 类库中。



传统的自然语言处理通常以单词为基本处理单元，模型都依赖预先确定的词表 V ，在编码输入词序列时，这些词表示模型只能处理词表中存在的词。因此，在使用中，如果遇到不在词表中的未登录词，模型无法为其生成对应的表示，只能给予这些**未登录词 (Out-of-Vocabulary, OOV)** 一个默认的通用表示。

在深度学习模型中，词表示模型会预先在词表中加入一个**默认的 “[UNK]” (unknown) 标识**，表示未知词，并在训练的过程中将[UNK] 的向量作为词表示矩阵的一部分一起训练，通过引入某些相应机制来更新[UNK] 向量的参数。在使用时，对于全部的未登录词，都使用[UNK] 的向量作为这些词的表示向量。



基于固定词表的词表示模型对词表大小的选择比较敏感。

- 当词表大小**过小时**，未登录词的比例较高，影响模型性能。
- 当词表大小**过大时**，大量低频词出现在词表中，而这些词的词向量很难得到充分学习。
- 理想模式下，词表示模型应能覆盖绝大部分的输入词，并避免词表过大所造成的数据稀疏问题。

为了缓解未登录词问题，一些工作通过利用**亚词级别的信息构造词表示向量**。一种直接的解决思路是为输入建立**字符级别表示**，并通过字符向量的组合来获得每个单词的表示，以解决数据稀疏问题。然而，单词中的词根、词缀等构词模式往往跨越多个字符，**基于字符表示的方法很难学习跨度较大的模式**。



为了充分学习这些构词模式，研究人员们提出了**子词词元化 (Subword Tokenization)** 方法，试图缓解上文介绍的未登录词问题。

词元表示模型会维护一个词元词表，其中既存在完整的单词，也存在形如 “c” , “re” , “ing” 等单词部分信息，称为**子词 (Subword)** 。

词元表示模型对词表中的每个词元计算一个定长向量表示，供下游模型使用。对于输入的词序列，词元表示模型将每个词拆分为词表内的词元。

例如，将单词 “reborn” 拆分为 “re” 和 “born” 。

模型随后查询每个词元的表示，将输入重新组成为词元表示序列。当下游模型需要计算一个单词或词组的表示时，可以将对应范围内的词元表示合成为需要的表示。




词元表示模型能够较好地解决自然语言处理系统中未登录词的问题。**词元分析 (Tokenization)** 目标是将原始文本分割成由词元 (Token) 序列的过程。词元切分也是数据预处理中至关重要的一步。

字节对编码 (Byte Pair Encoding, BPE) 模型[103] 是一种常见的子词词元模型。该模型采用的词表包含最常见的单词及高频出现的子词。在使用时，常见词通常本身位于BPE 词表中，而罕见词通常能被分解为若干个包含在BPE 词表中的词元，从而大幅降低未登录词的比例。BPE算法包括两个部分：

- (1) 词元词表的确定。
- (2) 全词切分为词元以及词元合并为全词的方法。



BPE 模型中词元词表的计算过程



首先，确定语料库中全词的词表和词频，然后将每个单词切分为单个字符的序列，并在序列最后添加符号

“</w>”作为单词结尾的标识。所切分出的序列元素称为字节，即每个单词都切分为字节的序列。之后，按照每个字节序列的相邻字节对和单词的词频，统计每个相邻字节对的出现频率，合并出现频率最高的字节对，将其作为新的词元加入词表，并将全部单词中的该字节对合并为新的单一字节。重复这一步骤，直至BPE 词元词表的大小达到指定的预设值，或没有可合并的字节对为止。

目录

Contents

3.1

数据来源

3.2

数据处理

3.3

数据影响分析

3.4

开源数据集

3.5

实践思考



大语言模型的训练需要巨大的计算资源，通常不可能多次迭代大语言模型预训练。千亿级参数量的大语言模型每次预训练的计算需要花费数百万元。因此，在训练大语言模型之前，构建一个准备充分的预训练语料库尤为重要。

本节将从**数据规模、数据质量和数据多样性**三个方面分析数据对大语言模型的性能影响。

需要特别说明的是，截止本书成稿时，由于在千亿参数规模的大语言模型上进行实验的成本非常高，很多结论是在100亿甚至是10亿规模的语言模型上进行的实验，其结果并不能完整地反映数据对大语言模型的影响。此外，一些观点仍处于猜想阶段，需要进一步验证。需要各位读者甄别判断。



随着大语言模型参数规模的增加，为了有效地训练模型，需要收集足够数量的高质量数据[37, 106]。在文献[106] 针对模型参数规模、训练数据量及总计算量与模型效果之间关系的研究之前，大部分大语言模型训练所采用的训练数据量相较于 LLaMA 等最新的大语言模型都少很多。

表 3.1 模型参数量与训练语料数量对比

模型名称	参数量 (个)	训练数据量 (词元)
LaMDA ^[15]	1 370 亿	1 680 亿
GPT-3 ^[46]	1 750 亿	3 000 亿
Jurassic ^[107]	1 780 亿	3 000 亿
Gopher ^[89]	2 800 亿	3 000 亿
MT-NLG 530B ^[108]	5 300 亿	2 700 亿
Chinchilla ^[106]	700 亿	14 000 亿
Falcon ^[64]	400 亿	10 000 亿
LLaMA ^[37]	630 亿	14 000 亿
LLaMA-2 ^[109]	700 亿	20 000 亿



DeepMind 的研究人员在文献[106] 中给出了他们通过训练参数范围从7000万到160亿，训练词元数量从5亿到5000亿不等的**400多个语言模型**所得出的分析结果。

- 研究发现，如果希望模型训练达到计算最优（Compute-optimal），则**模型大小和训练词元数量应该等比例缩放**，即模型大小加倍则训练词元数量也应该加倍。
- 为了验证该分析结果，他们使用与Gopher 语言模型训练相同的计算资源，根据上述理论预测了Chinchilla 语言模型的最优参数量与词元数量组合。最终确定Chinchilla 语言模型为700 亿参数，使用了1.4 万亿词元进行训练。
- 通过实验发现，Chinchilla在很多下游评估任务中都显著地优于Gopher（280B）、GPT-3（175B）、Jurassic-1（178B）以及Megatron-Turing NLG（530B）。



图3.5 给出了在同等计算量情况下，训练损失随参数数量的变化情况。针对9种不同的训练参数量设置，使用不同词元数量的训练语料，训练不同大小的模型参数量，使得最终训练所需浮点运算数达到预定目标。

图中**绿色线表示使用Gopher训练计算量所预测的最佳模型参数量和训练数据词元数量**。还可以使用幂律（PowerLaw）对计算量限制、损失最优模型参数量大小及训练词元数之间的关系进行建模。




图 3.5 在同等计算量情况下，训练损失随参数数量的变化情况^[106]



LLaMA[37] 模型在训练时采用了与文献[106] 相符的训练策略。研究发现，70 亿参数的语言模型在训练超过1万亿个词元（1T Tokens）后，性能仍在持续增长。因此，Meta 的研究人员在**LLaMA-2[109]** 模型训练中，进一步增大了训练数据量，训练数据量达到**2万亿词元**。

文献[106] 给出了不同参数量模型在训练期间，随着训练数据量的增加，模型在问答和常识推理任务上的效果演变过程，如图3.6 所示。研究人员分别在TriviaQA、HellaSwag、NaturalQuestions、SIQA、WinoGrande、PIQA 这6 个数据集上进行了测试。



可以看到，随着训练数据量的不断增加，模型在分属两类任务的6 个数据集上的性能都在稳步提高。通过使用更多的数据和更长的训练时间，较小的模型也可以实现良好的性能。




图 3.6 LLaMA 模型训练期间在问答和常识推理任务上的效果演变^[37]



使用经过过滤和去重的MassiveWeb 数据训练得到的语言模型在三个任务上都远好于使用未经处理的数据训练得到的模型。使用经过处理的MassiveWeb 数据训练得到的语言模型在下游任务上的表现也远好于使用OpenWebText 和C4 数据集训练得到的结果。




图 3.7 Gopher 语言模型使用不同数据质量训练后的效果分析^[89]



Google Research 的研究人员针对数据构建时间、文本质量、是否包含有害信息开展了系统的研究[113]。使用具有不同时间、毒性和质量及领域组成的数据，训练了28个15 亿参数的仅有解码器（Decoder-only）结构语言模型。研究表明，**大语言模型训练数据的时间、内容过滤方法及数据源对下游模型行为具有显著影响。**

针对数据时效性对于模型效果的影响问题，研究人员在C4语料集的2013、2016、2019 和 2022 版本上训练了4个自回归语言模型。对于每个版本，从CommonCrawl 数据集上删除了截止年份之后爬取的所有数据。使用新闻、Twitter 和科学领域的评估任务来衡量时间错位的影响。

这些评估任务的训练集和测试集按年份划分，分别在每个按年份划分的数据集上微调模型，然后在所有年份划分的测试集上进行评估。



图3.9 给出了使用4 个不同版本的数据集训练得到的模型在5个不同任务上的评测结果。热力图颜色（Heatmap Colors）根据每一列进行归一化得到。从图中可以看到，**训练数据和测试数据的时间错配会在一定程度上影响模型的效果。**




图 3.9 训练数据和测试数据在时间错配情况下的性能分析^[113]



Anthropic 的研究人员针对数据集中的重复问题开展了系统研究[96]。为了研究数据重复对大语言模型的影响，研究人员构建了特定的数据集，其中大部分数据是唯一的，只有一小部分数据被重复多次，并使用这个数据集训练了一组模型。研究发现了一个强烈的双峰下降现象，即重复数据可能会导致训练损失在中间阶段增加。

例如，**通过将0.1%的数据重复100次**，即使其余90%的训练数据保持不变，一个800M 参数的模型的性能也可能降低到与400M 参数的模型相同。此外，研究人员还设计了一个简单的复制评估，**即将哈利·波特（Harry Potter）的文字复制11 次**，计算模型在该段上的损失。**在仅有3%的重复数据的情况下**，训练过程中性能最差的轮次仅能达到参数量为1/3的模型的效果。



文献[14] 对大语言模型的记忆能力进行分析，根据训练样例在训练数据中出现的次数，显示了记忆率的变化情况，如图3.10 所示。




图 3.10 大语言模型记忆能力评测^[14]

可以看到，对于在训练中只见过一次的样例，PaLM 模型的记忆率为0.75%，**而对见过500 次以上的样例的记忆率超过40%**。这也在一定程度上说明重复数据对于语言模型建模具有重要影响。这也可能进一步影响使用上下文学习的大语言模型的泛化能力。由于 PaLM 模型仅使用了文档级别过滤，因此片段级别（100 个以上Token）可能出现非常高的重复次数。



来自不同领域、使用不同语言、应用于不同场景的训练数据具有不同的语言特征，包含不同语义知识。通过使用不同来源的数据进行训练，大语言模型可以获得广泛的知识。

表 3.2 LLaMA 模型所使用的数据集^[109]

数据集	采样概率	训练轮数	存储空间
CommonCrawl	67.0%	1.10	3.3 TB
C4	15.0%	1.06	783 GB
GitHub	4.5%	0.64	328 GB
Wikipedia	4.5%	2.45	83 GB
Books	4.5%	2.23	85 GB
ArXiv	2.5%	1.06	92 GB
StackExchange	2.0%	1.03	78 GB



Gopher 模型[89] 的训练过程对数据分布进行了消融实验，验证混合来源对下游任务的影响情况。针对MassiveText 子集设置了不同权重的数据组合，并用于训练语言模型。利用Wikitext103、Lambada、C4 和Curation Corpus 测试不同权重组合训练得到的语言模型在下游任务上的性能。

为了限制数据组合分布范围，实验中固定了Wikipedia 和GitHub 两个数据集的采样权重。对于Wikipedia，要求对训练数据进行完整的学习，因此将采样权重固定为2%；对于GitHub，采样权重设置为3%。对于剩余的4 个子集（MassiveWeb、News、Books 和C4）设置了7 种不同的组合。



图3.11 给出了7 种不同子集采样权重训练得到Gopher 模型在下游任务上的性能。可以看到，使用不同数量子集采样权重训练，所获得的模型效果差别很大。

- 在所有任务中表现良好且在Curation Corpus 上取得最佳表现的绿色配置是10% 的C4、50% 的MassiveWeb、30% 的Books 和10% 的News。增加书籍数据的比例可以提高模型从文本中捕获长期依赖关系的能力，因此可以降低Lambada 语料集[114] 上的损失。而使用更高比例的C4 数据集[19] 则有助于在C4验证集[89] 上获得更好的表现。




图 3.11 采用不同采样权重训练得到的 Gopher 语言模型在下游任务上的性能^[89]

目录

Contents

3.1

数据来源

3.2

数据处理

3.3

数据影响分析

3.4

开源数据集

3.5

实践思考




随着基于统计机器学习的自然语言处理算法的发展，以及信息检索研究的需求，特别是近年来深度学习和预训练语言模型的研究，研究人员构建了多种大规模开源数据集，涵盖了网页、图书、论文、百科等多个领域。

在构建大语言模型时，数据的质量和多样性对于提高模型的性能至关重要。同时，为了推动大语言模型的研究和应用，学术界和工业界也开放了多个针对大语言模型的开源数据集。



RefinedWeb[64] 是由位于阿布扎比的技术创新研究院（Technology Innovation Institute, TII）在开发Falcon 大语言模型时同步开源的大语言模型预训练集合，其主要由从CommonCrawl 数据集[128] 过滤的高质量数据组成。



RefinedWeb 中CommonCrawl 数据集过滤流程和数据过滤百分比



文档准备阶段主要是进行URL 过滤、文本提取和语言识别三个任务

过滤阶段主要包含重复去除、文档过滤、逐行纠正三个任务

冗余去除阶段包含模糊冗余去除、严格冗余去除及URL 冗余去除三个任务

文献[64] 还对三个阶段所产生的数据分别训练10 亿和30 亿模型，并使用零样本泛化能力对模型结果进行评测。发现REFINEDWEB 的效果远好于RW-RAW 和RW-FILTERED。这也在一定程度上说明**高质量数据集对语言模型具有重要的影响**。

本章小结

大语言模型训练需要数万亿的各类型数据。如何构造海量“高质量”数据对于大语言模型的训练具有至关重要的作用。从此前的研究来看，预训练数据需要涵盖各种类型，包括网络数据、图书、论文、百科和社交媒体等，还需要覆盖尽可能多的领域、语言、文化和视角，从而提高大语言模型的泛化能力和适应性。

本章介绍了常见的大语言模型训练数据的来源、处理方法、预训练数据对大语言模型影响的分析以及开源数据集等。